

LLMs in Papers @ MSc FMFI 2027

Vladimír Tischler

March 2026

1 Paper: Fabrication and errors in the bibliographic citations generated by ChatGPT

Hlavnou úlohou článku nebolo dospieť k jedinému definitívnemu záveru o využiteľnosti umelej inteligencie, ale skôr kriticky poukázať na mieru chybovosti pri generovaní citácií v odborných textoch. Zistenia štúdie majú slúžiť ako dôležitý upozornenie pre akademickú a vedeckú obec, aby sa hlbšie zamyslela nad vierohodnosťou článkov a citácií generovaných týmito nástrojmi. V ére generatívnej AI je nevyhnutné klásť zvýšený dôraz na zachovanie akademickej integrity, čo v praxi znamená potrebu dôsledného dohľadávania primárnych zdrojov a manuálneho overovania každého faktu.

Z technického hľadiska je kľúčové si uvedomiť, že ChatGPT nie je nástroj na spracovanie informácií v zmysle databázového vyhľadávania, ale nástroj na spracovanie jazyka. Funguje na princípe predpovedania nasledujúceho slova v sekvencii na základe štatistickej pravdepodobnosti naučenej počas tréningu, a nie na základe vnútornej reprezentácie faktov alebo pravdy. Kvôli tomuto mechanizmu nedokáže model rozlíšiť medzi presnou a nepravdivou informáciou, čo vedie k tzv. halucináciám – v tomto prípade k vytváraniu fiktívnych bibliografických záznamov, ktoré na prvý pohľad vyzerajú legitímne.

1.1 Metodika porovnávania modelov

Štúdia sa zamerala na porovnanie dvoch hlavných verzií nástroja: ChatGPT-3.5 a ChatGPT-4, s cieľom určiť, ktorý z nich vykazuje vyššiu mieru chybovosti.

1.1.1 Proces testovania prebiehal nasledovne:

Pre každý zo 42 multidisciplinárnych okruhov bol zadaný základný prompt, ktorý inštruoval model, aby vystupoval ako akademický výskumník a napísal článok v rozsahu približne 2000 slov s bibliografiou obsahujúcou aspoň 5 vedeckých zdrojov. Keďže ChatGPT má obmedzenú dĺžku výstupu na jednu odpoveď, výskumníci opakovane zadávali prompt *Please continue*“, aby model dokončil text presne tam, kde prestal. Následne boli overované všetky vygenerované citácie v databázach ako Google Scholar, PubMed či Scopus.

Výskumníci rozlišovali medzi vymyslenými (fabricated) citáciami, ktoré vôbec neexistujú, a reálnymi citáciami, ktoré však obsahovali vecné chyby (napr. preklepy v menách autorov, nesprávny názov článku, chybný rok vydania alebo nesprávne čísla strán).

1.1.2 Výsledky a porovnanie modelov

Výsledky jasne ukazujú, že ChatGPT-4 predstavuje výrazné zlepšenie oproti verzii 3.5, hoci ani on nie je bezchybný. Model GPT-4 vykazoval nižšiu mieru halucinácií, generoval citácie s menším počtom chýb a v priemere dokázal pre jeden článok vyprodukovať viac referencií. Zatiaľ čo GPT-3.5 mal problém splniť požiadavku na minimálne 5 citácií v takmer 30 % prípadov, GPT-4 túto podmienku splnil v každom jednom vygenerovanom článku. Konkrétne číselné porovnanie modelov: Táto tabuľka sumarizuje kľúčové metriky zo štúdie, kde

Table 1: Porovnanie výkonu modelov ChatGPT-3.5 a ChatGPT-4 pri generovaní akademických textov a citácií

Ukazovateľ	ChatGPT-3.5	ChatGPT-4
Percento vymyslených (fiktívnych) citácií [2, 5]	55 %	18 %
Percento reálnych citácií s vecnými chybami [3, 5]	43 %	24 %
Priemerný počet citácií na jeden článok [1]	5,3	9,9
Priemerná dĺžka textu (počet slov) [1]	834	1003
Percento článkov s 5 a viac citáciami [1]	71 %	100 %
Chybovosť v menách autorov (u reálnych diel) [3]	14 %	6 %
Chybovosť v číslach (ročník, vydanie, strany) [4]	34 %	13 %

GPT-4 preukázal výrazne vyššiu presnosť a nižšiu mieru halucinácií v porovnaní s verzou 3.5. Napriek zlepšeniu však zdroje uvádzajú, že GPT-4 stále generuje fiktívne citácie (najmä pri kapitolách v knihách, kde je chybovosť až 70 %) a vykazuje vecné chyby v číselných údajoch reálnych diel. Pre akademickú prax to znamená, že tieto nástroje môžu slúžiť ako pomocníci, ale v žiadnom prípade by nemali nahradiť samostatnú rešeršnú prácu výskumníka.

2 A pipeline for matching bibliographic references with incomplete metadata: experiments with Crossref and OpenCitations

Ide o prácu tímu z University of Bologna, ktorá rieši zásadný problém v oblasti Open Science a spracovania vedeckých dát: ako prepojiť citácie, ktoré nemajú jednoznačný identifikátor (DOI).

2.1 Motivácia

Vedecká komunikácia stojí na citáciách, ktoré umožňujú pripisovanie zásluh a štúdium dynamiky vedeckých domén. Hoci iniciatívy ako I4OC (Initiative for Open Citations) dosiahli, že vydavatelia uvoľňujú zoznamy referencií, stále narážame na problém neúplných dát.

2.1.1 Problémy

Databáza Crossref obsahuje viac ako 1,8 miliardy referencií, ale viac ako 698 miliónov z nich nemá priradené DOI. Súčasný systém (ako OpenCitations) pri spracovaní dát z Crossrefu referencie bez DOI jednoducho zahadzuje, čím strácame obrovské množstvo informácií o citačnej sieti.

Cieľom autorov bolo navrhnúť heuristický pipeline, ktorý dokáže mapovať tieto neúplné alebo neštruktúrované referencie na existujúce entity v databáze OpenCitations Meta.

2.2 Metodológia a architektúra systému

Autori navrhli proces rozdelený do štyroch bodoch:

Zber a príprava dát: Extrakcia referencií z JSON formátu Crossrefu a XML-TEI formátu manuálne overeného "Gold Standardu".

Matching bibliografických metadát: Jadro systému postavené na kaskádovej stratégii.

Fallback krok (Enrichment): Ak matching zlyhá, nastupuje nástroj GROBID na extrakciu metadát z neštruktúrovaných textových reťazcov.

Export a evaluácia: Generovanie výsledkov v CSV a HTML formáte pre ďalšiu analýzu

2.2.1 Kaskádová stratégia dopytovania (SPARQL)

Systém nevykonáva len jeden dopyt, ale postupuje podľa priority od najpresnejších kritérií po uvoľnenejšie. Využíva pritom SPARQL endpoint OpenCitations Meta.

2.2.2 Poradie dopytov

Q1 & Q2: Matchovanie na základe DOI (ak je dostupné) v kombinácii s rokom alebo názvom.

Q3 (Autor & Názov): Hľadanie zhody prvého autora a názvu diela (považované za vysoko distinkatívne).

Q4 (Rok, Autor, Strana): Zamerané na prípady, kde chýba informácia o zväzku (volume).

Q5 (Rok, Volume, Strana): Typická kombinácia pre unikátnu identifikáciu článku v rámci žurnálu.

Q6 (Rok, Autor, Volume): Posledný fallback pred použitím GROBIDu.

2.3 Skórovací algoritmus a rozhodovanie

Bodové ohodnotenie metadát:

DOI (presná zhoda): 15 bodov.

Názov (Title): Škálované od 14 bodov (100% zhoda) po 10 bodov (75% podobnosť). Používa sa fuzzy matching (Partial Ratio, Token Sort Ratio).

Autor (presná zhoda): 7 bodov.

Strana (Page): 8 bodov (validácia začiatkovej aj koncovkej strany).

Volume: 3 body.

Rok: 1 bod za presnú zhodu.

Prahová hodnota (Threshold) Maximálny počet bodov je 48. Štandardný prah pre prijatie zhody je nastavený na 26 bodov (cca 54,5 %). Systém obsahuje aj adaptívny mechanizmus: ak najlepší kandidát dosiahne aspoň 90 % prahu (t. j. 23 bodov), prah sa dynamicky zníži, aby sa zachytili validné zhody s drobnými nekonzistentnosťami v metadátach.

2.3.1 GROBID Fallback

Ak metadáta z Crossrefu nestačia na dosiahnutie prahu, systém pošle neštruktúrovaný textový reťazec do nástroja GROBID (knížnica založená na strojovom učení). Ten extrahuje chýbajúce polia (rok, autor, názov atď.), ktoré sa následne zlúčia s pôvodnými dátami a proces matchingu sa zopakuje.

2.4 Experimentálne výsledky

Evaluácia prebehla na dvoch datasetoch: manuálnom Gold Standarde (112 dokumentov) a reálnej vzorke z Crossrefu (100 súborov).

Table 2: Kľúčové metriky výkonnosti pre Gold Standard a Crossref datasety

Metrika	Gold Standard	Crossref (s DOI query)	Crossref (bez DOI query)
Precision (Presnosť)	100%	100%	100%
Recall (Návratnosť)	75,67%	69,45%	58,31%
F1 Score	86,15%	81,97%	73,67%

Zistenie: Systém dosiahol dokonalú presnosť (100 %) v oboch prípadoch, čo znamená, že prakticky nedochádza k falošne pozitívnym výsledkom (nesprávnym prepojeniam). Nižšia návratnosť pri reálnych dátach z Crossrefu je spôsobená nekonzistentnosťou metadát od rôznych vydavateľov.

2.5 Limity

Nekonzistencia rokov: Často existuje rozdiel ± 1 rok medzi rôznymi databázami kvôli dátumu online publikovania vs. tlačenej verzii. Systém preto implementuje toleranciu na susediace roky.

Jazykové bariéry: Súčasný model predpokladá latinku. Pri dielach v čínštine, arabčine alebo cyrilike systém zlyháva, čo predstavuje priestor pre budúce využitie automatickej transliterácie.

Závislosť na DOI pri evaluácii: Keďže evaluácia porovnávala výsledky voči DOI, úspešné zhody referencií, ktoré DOI vôbec nemajú, neboli v metrikách započítané (čo môže znamenať, že reálna návratnosť je vyššia, než ukazujú čísla).

2.6 Záver

Ak by sa tento pipeline nasadil na celý dump Crossrefu z apríla 2025 (kde je 698 miliónov referencií bez DOI), autori odhadujú, že by dokázali do infraštruktúry OpenCitations pridať približne 404 miliónov nových citačných prepojení (pri 58 % úspešnosti).

3 CiteME: Can Language Models Accurately Cite Scientific Claims?

Vedecký pokrok prináša tisíce nových prác mesačne, čo vedcom sťažuje sledovanie stavu poznania (SoTA) a overovanie tvrdení. Autori definujú úlohu priradovania citácií (citation attribution): ak máme k dispozícii textový úryvok, ktorý odkazuje na nejakú prácu, dokáže systém (napr. LLM) správne identifikovať a uviesť názov citovaného dokumentu?

Súčasný benchmark na predpovedanie citácií majú podľa autorov zásadné nedostatky:

- Sú generované automaticky, čo vedie k vysokej miere ambivalencie (viacero možných prác pre jeden citát) alebo nepriraditeľnosti (úryvok neobsahuje dost informácií na identifikáciu zdroja).
- Často obsahujú triviálne prípady, kde je meno autora alebo skratka názvu priamo v texte, čo testuje len pamäť modelu, nie jeho schopnosť vyhľadávania a dedukcie.
- Tradičné metódy sa zameriavajú na vyhľadávanie v malom vopred vybranom korpuse a pracujú len s názvami a abstraktmi, nie s plným textom.

3.1 Benchmark CiteME

Na riešenie týchto nedostatkov autori vytvorili CiteME (Citation for Model Evaluation). Ide manuálne kurátorovaný benchmark pre jednoznačné priradovanie vedeckých citácií.

Vlastnosti CiteME:

- **Manuálna expertíza:** Na tvorbe sa podieľal tím doktorandov v odbore strojového učenia, ktorí vyberali úryvky tak, aby jednoznačne odkazovali na jedinú prácu a poskytovali dostatočný kontext.

- **Filtrovanie ľahkých“ príkladov:** Z pôvodného výberu odstránili všetky vzorky, ktoré dokázal GPT-4o správne zodpovedať bez prístupu k internetu (len na základe svojich natrénovaných vedomostí), aby benchmark skutočne testoval schopnosť výskumného asistenta vyhľadávať informácie.
- **Rozsah a zameranie:** Obsahuje 130 otázok. Hoci sa to môže zdať málo v porovnaní s miliónovými datasetmi, autori argumentujú, že moderné LLM benchmarky (ako HumanEval) bežne pracujú so 100 – 200 vzorkami a sú vysoko informatívne.
- **Aktuálnosť:** Väčšina úryvkov pochádza z prác publikovaných v posledných rokoch (2021 – 2024), čo je v dynamickom poli AI kľúčové.
- **Ľudský výkon:** Experti dosiahli na CiteME úspešnosť 69,7%, pričom im nájdenie citácie trvalo v priemere len 38,2 sekundy. To vytvára jasnú latku pre systémy AI.

3.2 Systém CiteAgent

Autori neprišli len s benchmarkom, ale aj so systémom CiteAgent, ktorý má napodobňovať prácu vedca. CiteAgent nie je len pasívny model, ale agent, ktorý aktívne využíva nástroje.

3.2.1 Architektúra a fungovanie

- **Jadro:** Využíva modely ako GPT-4o, Claude 3 Opus alebo LLaMA-3 ako mozog systému.
- **Nástroje:** Agent má prístup k vyhľadávaču Semantic Scholar.
- **Príkazy (Commands):**
 - search(query, sort): Vyhľadá prácu podľa relevancie alebo počtu citácií.
 - read(ID): Extrahuje a prečíta plný text PDF dokumentu.
 - select(ID): Finálny výber citovanej práce.
- **Iteratívny proces:** Agent vygeneruje ”myšlienku”, vykoná akciu, pozoruje výsledok a proces opakuje (až do 15 krokov), kým nie je pripravený urobiť výber.

3.3 Experimentálne výsledky a porovnanie

- **Baseline modely (SPECTER):** Použili modely SPECTER a SPECTER2, ktoré sú de facto štandardom pre vedecké reprezentácie (embeddings). Tieto modely porovnávali vstupy s celým korpusom Semantic Scholar (cca 218 miliónov prác) pomocou techniky kNN (k-najbližších susedov) na základe kosínusovej podobnosti.

- **Konfigurácie CiteAgent:** Testovali tri hlavné LLM: GPT-4o, Claude 3 Opus a LLaMA-3-70B. Pre každú vytvorili šesť verzií podľa dostupných príkazov a promptov:
 1. Search and Read: Agent môže hľadať aj čítať plné texty (LLaMA-3 bola z tohto vynechaná kvôli malému 8k context window, ktoré na PDF nestačilo).
 2. Search Only: Agent môže len vyhľadávať.
 3. No Commands: Model odpovedá len na základe svojich natrénovaných vedomostí.
- **Demonštračné trajektórie:** Každú konfiguráciu testovali s demo ukážkou v prompte (w/ Demo) a bez nej (w/o Demo).

3.4 Analýza výsledkov

Výsledky ukázali, že priraďovanie citácií je momentálne pre AI náročná úloha.

Celková úspešnosť: CiteAgent (GPT-4o) dosiahol maximum 35,3 %, zatiaľ čo ľudia až 69,7%. SPECTER modely dopadli zle s 0% úspešnosťou. **Vplyv príkazov a promptov:**

- GPT-4o bol jediný model, ktorý sa reálne zlepšoval s pribúdajúcimi nástrojmi. Keď mohol čítať celé texty, jeho výkon rástol.
- Claude a LLaMA paradoxne dopadli horšie, keď dostali demo ukážku. Autori to pripisujú tomu, že dlhý prompt im sťažil hľadanie podstatných informácií.

3.4.1 Analýza chýb (Error Analysis):

- Nepochopenie úryvku (50 % chýb): Model sa zameral na nesprávnu časť textu alebo prehliadol dôležitý detail (napríklad si pomýlil meno autora z predchádzajúcej vety s hľadanou citáciou).
- Predčasné ukončenie (32 % chýb): Model našiel prácu, ktorá sa téme venovala len približne, a uspokojil sa s ňou.
- Zámena s citujúcou prácou (18 % chýb): Agent našiel článok, ktorý správne citoval hľadaný zdroj, ale namiesto toho, aby dohľadal ten pôvodný, označil ako odpoveď tento článok.
- Technické chyby (5,8 %): Problémy s formátovaním JSON výstupu alebo chyby v API Semantic Scholar.

3.4.2 Testovanie najnovších modelov

- Claude 3.5 Sonnet: Prekonal verziu Opus a dosiahol 40,3% (Search and Read), čo ukazuje na lepšiu schopnosť uvažovania.
- LLaMA-3.1-70B: Zlepšila sa o 8 % oproti verzii 3.0, najmä vďaka schopnosti lepšie spracovať kontext.
- Model o1-preview: Dosiahol rekordných 61,3 %. Autori sú však opatrní, pretože tento model dokázal bez internetu uhádnuť takmer 39 % vzoriek, čo môže byť spôsobené tým, že časť datasetu už mal v tréningových dátach.

Úspešné pokusy trvali modelom zvyčajne 5 krokov alebo menej, kým naši správnu odpoveď. Ak model nenašiel odpoveď rýchlo, s predlžujúcim sa kontextom jeho šanca na úspech prudko klesala.

3.5 Záver

Článok ukazuje, že hoci sú výsledky LLM zaujímavé, v úlohe vedeckých asistentov sa ešte nedajú moc dobre používať (34,4 % rozdiel oproti ľuďom). CiteME slúži ako dôležitý test pre reasoning schopnosti modelov.

4 Zero-shot Scientific Claim Verification Using LLMs and Citation Text

Tradičné metódy sa spoliehali na manuálne anotované datasety, kde experti formulovali tvrdenia a priradzovali k nim dôkazy z literatúry. Tento proces je však nákladný a ťažko škálovateľný. Autori článku skúmajú, či je možné tento proces zefektívniť pomocou veľkých jazykových modelov (LLM) a využitím citácií priamo ako labeled dáta, čím by sa eliminovala potreba manuálneho prepisovania tvrdení.

Otázky, ktorými sa zaujímali autori:

Sú pre trénovanie a overovanie nevyhnutné tvrdenia napísané expertmi, alebo stačia priame citácie z literatúry? Dokážu LLM v zero-shot alebo few-shot nastavení overovať vedecké tvrdenia bez potreby jemného ladenia (fine-tuning) na labeled dátach?

4.1 Dataset SCitance

Autori vytvorili dataset SCitance, ktorý je odvodený z existujúceho datasetu SciFact. Na rozdiel od SciFact, ktorý obsahuje 1 400 expertmi prepísaných tvrdení, SCitance využíva pôvodné citačné vety z biomedicínskych prác mapované na dokumenty s dôkazmi.

Dataset obsahuje páry citácia-dôkaz s labelmi: SUPPORT (podporuje), REFUTE (vyvracia) a NEI (Not Enough Information – nedostatok informácií).

Celkovo obsahuje 656 inšancií (251 Support, 225 Refute, 180 NEI) rozdelených na tréningovú, vývojovú a testovaciu množinu.

Počet inšancií v SCitance je nižší ako v SciFact, pretože v SciFact mohlo byť z jednej citácie vytvorených viacero tvrdení, zatiaľ čo v SCitance sa každá unikátna citácia s daným dôkazom počíta len raz.

4.1.1 Generovanie negácií pomocou LLM

Keďže mapovanie citácií na dôkazy poskytuje labely SUPPORT a NEI, bolo potrebné vytvoriť kontraproduktívne príklady-REFUTE. Na generovanie negácií bol zvolený GPT-3.5 (konkrétne model text-davinci-003). Autori testovali rôzne prompty a zistili, že najlepšie výsledky dosahuje prompt: Negujte túto vetu zmenou čo najmenšieho počtu slov v pôvodnej vete“.

4.2 Experimenty

Úlohou modelov bolo určiť pravdivostný label (Support/Refute/NEI).

Testované modely:

1. GPT-3.5 (gpt-3.5-turbo-0125)
2. GPT-4 (gpt-4-0613)
3. MultiVerS: Supervizovaný model (založený na Longformeri)

Režimy promptovania: Zero-shot (bez príkladov) a Few-shot (In-Context Learning – ICL s náhodne vybranými príkladmi pre každý label)

Pri testovaní na SCitance bol poskytnutý priamo relevantný abstrakt (gold abstract). Pri testovaní na SciFact sa používal hustý retrieval na vyhľadanie top 3 dokumentov.

4.3 Výsledky

4.3.1 Dataset SCitance

V zero-shot nastavení dosiahol GPT-4 najlepší výsledok (80,1 Micro-F1), čo je viac ako MultiVerS (73,8 Micro-F1). GPT-3.5 v oboch režimoch výrazne zaostával (okolo 44 Micro-F1).

4.3.2 Dataset SciFact

Na pôvodnom datasete SciFact dosiahol GPT-4 v zero-shot nastavení (68,6 F1 s citáciami ako príkladmi) podobný výkon s plne natrénovaným modelom MultiVerS (72,5 F1). GPT-3.5 výrazne zaostával (okolo 38 F1).

4.4 Analýza lexikálneho skreslenia (Lexical Bias)

Autori skúmali, či proces generovania negácií nevnesol do dát skreslenia (napr. že model predpovedá REFUTE len na základe prítomnosti slova nie“). Pomocou GPT-2 merali perplexitu (zložitost) pôvodných citácií a vygenerovaných negácií. Štatistický test (T-test) ukázal, že rozdiel v distribúcii perplexity nie je signifikantný ($p = 0,468$), čo znamená, že negácie sú jazykovo prirodzené a nevykazujú zjavné lexikálne vzorce, ktoré by modely mohli zneužívať ako skratky.

4.5 Diskusia

1. Komplexita syntaxe: Negovanie zložitých vedeckých viet so zachovaním logických vzťahov zostáva výzvou, v ktorej modely niekedy zlyhávajú.
2. Vysvetliteľnosť: Štúdia sa nezameriavala na generovanie odôvodnení (explainability) pre verdikty, čo je vo vedeckom overovaní dôležité.
3. Doménové obmedzenie: Experimenty boli obmedzené na biomedicínsku oblasť a jeden hlavný dataset.
4. Závislosť na promptoch: Výkon modelov je citlivý na presnú formuláciu inštrukcií (prompt engineering).

4.6 Záver

Práca demonštruje, že využitie citačných viet priamo z literatúry v kombinácii s LLM ako GPT-4 predstavuje vhodnú alternatívu k manuálnej anotácii dát. GPT-4 s in-context učením dosahuje výsledky na úrovni špecializovaných, jemne ladených modelov, čo výrazne znižuje náklady na transfer overovacích systémov do nových vedeckých domén.